64 Squares

Qu'est-ce qui fait vraiment gagner aux échecs ? Analyse de 2 millions de parties Lichess, du fichier brut au tableau de bord.

Oussama Essalehi
Data Analyst
linkedin.com/in/oussama-essalehi · oussama-essalehi.dev

Question métier — pour une plateforme d'échecs en ligne : à chaque niveau, qu'est-ce qui fait gagner un joueur ? Son ouverture, sa couleur, sa gestion du temps, ou simplement son classement ?

89 616 462	2 000 201	1 958 145	897 800
parties dans le fichier du mois (29,2 Go), lues en flux	parties tirées au hasard (Bernoulli, graine fixe)	parties après 7 règles de nettoyage testées	joueurs distincts (pseudos hachés)

Le classement d'abord

+100 points d'écart multiplient les chances de victoire par **1,44**. Mais à +200 en blitz, le favori marque 67,9 % au lieu des 75,7 % prévus par la formule Elo.

La pendule ensuite

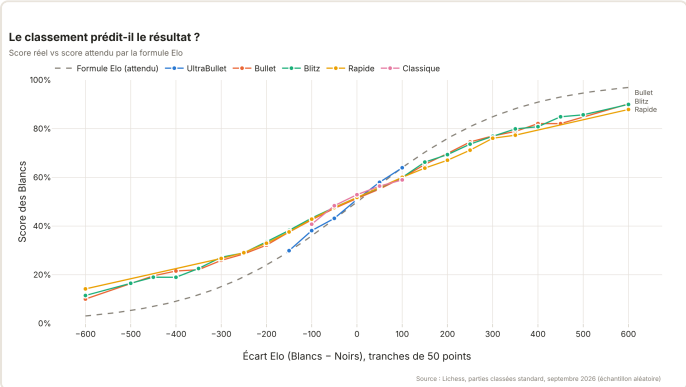
En blitz, les joueurs les plus lents sur leurs 10 premiers coups marquent **43,6 %** contre 52,3 % pour les plus rapides, et perdent au temps 21,4 % de leurs parties (contre 7,1 %).

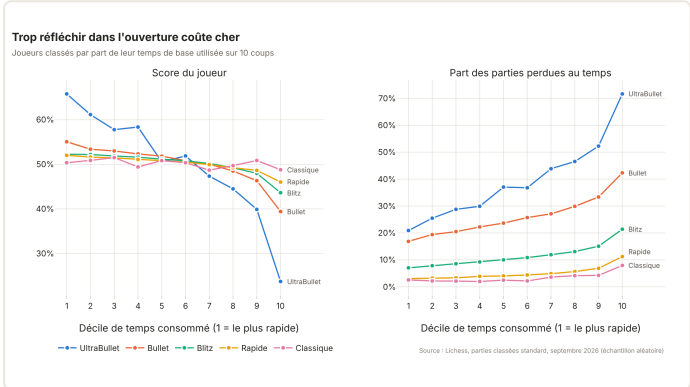
Un petit avantage aux Blancs

Score moyen de **51,6 %**, soit +1,6 point au-delà de ce que prédit le classement ; 31,5 % des parties se terminent au temps.

L'ouverture pèse peu

Khi² significatif dans toutes les tranches, mais V de Cramér ≤ **0,030**. Le répertoire change pourtant : la Sicilienne passe de 4,8 % à 12,8 % des parties.





Ce que j'ai construit

- **Pipeline Python** : streaming HTTP + zstandard, échantillonnage reproductible, Parquet, reprise sur erreur.
- **Modèle DuckDB** en étoile et requêtes SQL (CTE, fenêtres, ROLLUP / GROUPING SETS).
- **Statistiques** : Wilson, khi² + V de Cramér, calibration Elo, régression logistique.
- **Power BI** (PBIP : TMDL + PBIR validés), 4 pages, 19 mesures DAX, seuil d'échantillon.
- **Tableau de bord web** et **application « Analyse mes parties »** (API Lichess, conseils personnalisés).

Rigueur

- Minimum de 1 000 parties pour tout taux affiché.
- 140 tests automatisés ; recoupement SQL ↔ Python 6/6.
- Résultats identiques d'une exécution à l'autre.
- Palette vérifiée pour le daltonisme, aucun double axe.
- Aucun pseudo en clair, aucune donnée brute versionnée.

Données : base ouverte Lichess (CC0), septembre 2026. Code, méthode et limites : github.com/Oussama-essalehi/64-Squares. Corrélation ≠ causalité ; un seul mois ; joueurs en ligne non représentatifs de tous les joueurs.